Hackathon AI & ML
M1 ISA

Emmanuel Doumard – emmanuel.doumard@univ-tours.fr

Nicolas Labroche – nicolas.labroche@univ-tours.fr

Principe du hackathon

- Objectif : résoudre un problème de ML en une journée

- Compétition entre équipes de 4

Planning

- 8h30-9h00 : Présentation du hackathon
- 13h : Premier point d’avancement
- 15h : Second point d’avancement
- 17h : Présentation finale devant les autres groupes

Contexte

La médecine

- Les progrès de la médecine ont fortement allongé l’espérance de vie à la naissance
- Mais la fin de vie est encore très inégalitaire entre les individus

La mort

- La plupart des maladies augmentent le risque de mortalité
- Anticiper ces risques permet d’effectuer de la médecine préventive

Objectif du hackathon

- Prédire le statut de vie d'un patient en 2019
- Prédiction **binaire**
- L'évaluation de la prédiction se fera sur la base du **F1-score**

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Le jeu de données

- 59049 patients uniques majeurs (identifiés par SEQN)
- 1525 variables

Beaucoup de valeurs manquantes

- 4 catégories de variables
  - Issues de questionnaires
  - Issues d’examinations
  - Issues de prises de sang (laboratory)
  - Décrivant la situation démographique

Le jeu de données

- Les données ont été collectées entre 1999 et 2018
- La mortalité est statuée en 2019
- Le jeu de données fourni est déjà pré-filtré par un groupe de biologistes

Les enjeux du hackathon

- Il ne s’agit pas seulement de prédiction, mais aussi d’analyse
- Distributions des patients, prévalence de certaines pathologies, etc.
- Comment prédire efficacement la mortalité ?

Fichiers disponibles

- `data.csv` : Le jeu de données
- `features_metadata.csv` : Les informations des variables
- `ground_truth_train.csv` : Le statut de vie de 95 % des patients
- `test_indexes.csv` : La liste des individus sur laquelle votre soumission sera évaluée (10 % des patients)

Soumission des prédictions

- À l'URL suivante :
  - https://utbox.univ-tours.fr/s/mS8549YmdjmX4Tk
- Fichier csv :
  - Nommé "`[idgroupe]_[idsoumission].csv`"
  - Une ligne par prédiction
  - La soumission doit bien faire 5000 lignes et deux colonnes (SEQN, prediction)
  - Ordre croissant des SEQN
  - Pas de header

```
33,0
34,0
58,1
101,1
127,1
136,1
166,0
183,0
221,1
268,0
272,0
279,1
340,0
372,0
402,1
410,1
417,0
459,0
```

Évaluation

- Baseline /3 : Si vous dépassez le niveau de la baseline
- Compétition /3
- Méthodologie /5
- Analyse approfondie du sujet /5
- Clarté de la présentation /2
- Travail en équipe /2